

Vývoj toolkitu pro red-teaming velkých jazykových modelů (LLM)

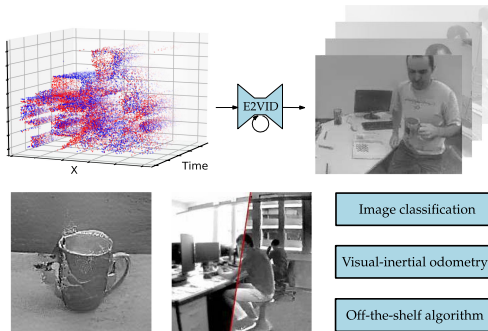
Adam Veselý

Vedoucí: Ing. Jakub Reš




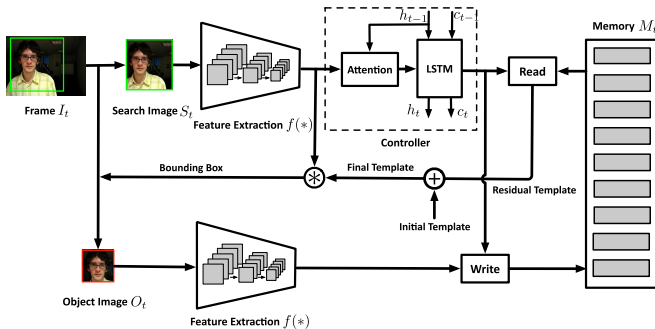
17. ledna 2026

- Vstupy či stav před
- Co mají být výstupy
- Odrážky žádné nebo aspoň stručné!
- Žádoucí: Schéma se vstupy a výstupy



- Vstup
- Výstup
- Žádoucí vlastnosti
- Využití & aplikace





$$\mathbf{a}_t = \sum_{i=1}^L \alpha_{t,i} \mathbf{f}_{t,i}^* \quad (1)$$

kde $\alpha_{t,i}$ počítá **softmax**:

$$\alpha_{t,i} = \frac{\exp(r_{t,i})}{\sum_{k=1}^L \exp(r_{t,k})} \quad (2)$$

$$r_{t,i} = W^a \tanh(W^h \mathbf{h}_{t-1} + W^f \mathbf{f}_{t,i}^* + b) \quad (3)$$

```

26         \right)
27     \end{align}
28 \end{frame}

```

Podstatné informácie o řešení

$$\mathbf{a}_{t,j} = \sum_{k=1}^L \alpha_{t,j} \mathbf{f}_{t,j}^{(k)} \quad (1)$$

kde $\alpha_{t,j}$ počítá softmax:

$$\alpha_{t,j} = \frac{\exp(r_{t,j})}{\sum_{k=1}^L \exp(r_{t,k})} \quad (2)$$

$$\mathbf{r}_{t,j} = \mathbf{W}^0 \mathbf{h}_{t-1} + \mathbf{W}^1 \mathbf{f}_{t,j}^{(b)} \quad (3)$$

Číslo rádku preverovaného počtu (číslo rádku výstupu denoisingu, číslo výstupu do featureu) 4/17

Podstatné informácie o řešení

$$\mathbf{a}_{t,j} = \sum_{k=1}^L \alpha_{t,j} \mathbf{f}_{t,j}^{(k)} \quad (1)$$



kde $\alpha_{t,j}$ počítá softmax:




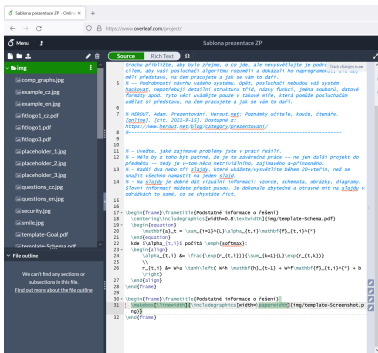
$$\alpha_{t,j} = \frac{\exp(r_{t,j})}{\sum_{k=1}^L \exp(r_{t,k})} \quad (2)$$

$$\mathbf{r}_{t,j} = \mathbf{W}^0 \mathbf{h}_{t-1} + \mathbf{W}^1 \mathbf{f}_{t,j}^{(b)} \quad (3)$$

- Co se **podařilo**
- Vytvořená datová sada: **105k** záznamů
- Úspěšnost: **103%**

	AN	RN	EA0 \uparrow	$\mathcal{J}_{\mathcal{M}\uparrow}$	$\mathcal{F}_{\mathcal{M}\uparrow}$	Speed
SiamFC	✓		0.188	-	-	86
SiamFC		✓	0.251	-	-	40
SiamRPN	✓		0.243	-	-	200
SiamRPN		✓	0.359	-	-	76
SiamMask-2B w/o R		✓	0.326	62.3	55.6	43
SiamMask w/o R		✓	0.375	68.6	57.8	58
SiamMask-2B-score		✓	0.265	-	-	40
SiamMask-box		✓	0.363	-	-	76
SiamMask-2B		✓	0.334	67.4	63.5	60
SiamMask		✓	0.380	71.7	67.8	55





- Pokud je otázek více, lze udělat i více slajdů.
- Tento slajd nechť je příloha, která se nepočítá do celkového počtu slajdů.
- Otázku je dobré sem přepsat *verbatim*, ať není pochybnost, jestli nedošlo k nepřesnému parafrázování.

